Self drives me crazy: from 0 to autonomous car in 150 hours



Paula Moraes

Quem somos:

- Felipe Salvatore: doutorando em Deep Learning/NLP
- Paula Moraes: mestranda com foco em Robótica Probabilística



Por que montar um carro autônomo?

- Desmistificar a implementação dessa tecnologia
- Porque é divertido :)



Desafio

Implementar o artigo: End to End Learning for Self-Driving Cars (2016)


Por que carros autônomos?

 Carros autônomos são os robôs que vão diretamente impactar nosso dia a dia no futuro próximo: atualmente há 51,3 milhões de veículos rodando no Brasil.

 Esse problema é rico para a inteligência artificial, pois junta diferentes áreas como machine learning, computer vision, path planning e reinforcement learning

Carro autônomo na universidade

DeepTraffic: Deep Reinforcement Learning



Fonte: MIT 6.S094: Deep Learning for Self-Driving Cars

Carro autônomo no Brasil: um breve histórico



End to End Learning for Self-Driving Cars




Figure 4: CNN architecture. The network has about 27 million connections and 250 thousand parameters.

Fonte: End to End Learning for Self-Driving Cars - Bojarski, M., et al.

Recursos utilizados

Webcam

Power bank







Lego NXT

Raspberry Pi


custo total: \$ 60


Robô com acionamento diferencial


- Sistema com duas rodas controladas por atuadores independentes
- Possui uma roda passiva (castor wheel) para maior estabilidade
- Benefícios:
 - simplicidade
 - permite girar no próprio eixo
- Movimentação baseada na diferença de velocidade entre os motores



Robô com acionamento diferencial








```
self.leftMotor = nxt.Motor(self.brick, nxt.PORT_B)
self.rightMotor = nxt.Motor(self.brick, nxt.PORT A)
self.both = nxt.SynchronizedMotors(self.leftMotor,
                                   self.rightMotor,
                                   turn ratio)
def move_up(self):
    self.both.run(self.power up)
def move left(self):
    Execute action of moving left for tacho left degrees
    self.rightMotor.weak_turn(self.power_left, self.tacho_left)
    self.leftMotor.weak turn(- self.power left, self.tacho left)
def move_right(self):
    Execute action of moving rigth for tacho right degrees
    self.rightMotor.weak turn(- self.power right, self.tacho right)
    self.leftMotor.weak turn(self.power right, self.tacho right)
```

Controle como regressão






Exemplos:

Udacity's Lincoln MKZ


DeepTesla


Classificação de imagens




Fonte: Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms- Xiao, K., et al.

Controle como classificação de imagens







Coleta de dados




Coleta de dados



Coleta de dados





Manipulação de imagens





Original

Binary



Random shadow





Grayscale



Gaussian Blur 5x5

Data pipeline





Resultados com DFN

architecture	preprocessing	hit rate ↑	hit rate \leftarrow	hit rate \rightarrow
[3]	none	0.80	0.76	0.68
[2350, 3]	none	0.80	0.70	0.80
[1333, 200, 3]	none	0.79	0.82	0.67
[3]	binarization	0.75	0.87	0.64
[233, 3]	binarization	0.72	0.85	0.82
[1628, 47, 3]	binarization	0.71	0.90	0.84

Resultados com CNN

architecture	preprocessing	hit rate ↑	hit rate \leftarrow	hit rate \rightarrow
[(24,5),731,3]	none	0.80	0.71	0.73
[(32,5),(64,5),3]	none	0.82	0.80	0.66
[(24,5),(36,5),(64,5),200,3]	none	0.76	0.84	0.72
[(24,5),456,3]	binarization	0.79	0.86	0.67
[(32,5),(64,5),3]	binarization	0.78	0.80	0.73
[(24,5),(36,5),(64,5),200,3]	binarization	0.79	0.83	0.73

Confusion matrix of 5682 examples accuracy = 0.790567

- 2000

- 1750

- 1500


- 1250

- 1000

- 750

- 500


- 250



Simulação



Primeira Tentativa




PROBLEMA: dados pouco informativos


Comando "ir para frente" estava fortemente associado ao robô estar centralizado na pista




Nova coleta de dados




Nova coleta de dados



Nova coleta de dados



Nova coleta de dados: + 13403 imagens




PROBLEMA: predição x controle

captura e processamento de imagem ~ 9 ms

command	time
†	$0.06 \mathrm{\ s}$
←	0.29 s
\rightarrow	0.29 s

architecture	preprocessing	inference time
[3]	none	$0.43 \mathrm{\ s}$
[1333, 200, 3]	none	$1.35 \mathrm{\ s}$
[(24,5),731,3]	none	1.41 s
[3]	binarization	$0.42 \mathrm{\ s}$
[233, 3]	binarization	$0.59 \mathrm{\ s}$
[(32,5),(64,5),3]	binarization	$0.89 \mathrm{\ s}$
[(24,5),(36,5),(64,5),200,3]	binarization	1.24 s

Confusion matrix of 10001 examples accuracy = 0.842616



Melhor modelo: [(36, 5), 3]

imagens RGB

2500

2000

1500


1000

500


uma camada de convolução:
36 filtros 5x5

- uma camada de pooling 2x2
- sem camadas escondidas
- tempo de inferência: 0.69 s

Modo autônomo - pista de treino



Pista de teste



Modo autônomo - pista de teste



Próximos passos

- Experimentar novos modelos de direção, e.g. modelo Ackerman
- Integrar o robô com outros sensores:
 - o GPS e Radar
- Detecção de obstáculos
- Path planning
 - Planejar trajetórias do ponto A ao ponto B

Conclusão

- Machine learning em aplicações reais é mais complicada do que em ambientes simulados
- Começar com deep learning para carro autônomo é fácil
- É possível implementar técnicas avançadas com hardware de baixo custo
- Variabilidade na coleta de dados é essencial
- O protótipo apresentado pode ser uma solução viável a disciplinas de inteligência artificial que desejem ir além de toy problems

Referências

- Artigo no Medium (@project_m)
 - Self drives me crazy: from 0 to autonomous car in 150 hours
- Código no GitHub
 - Self-Driving Pi Car
- Dataset
 - Self-Driving Data
- Curso do MIT:
 - Deep Learning for Self-Driving Cars

Agradecimentos





Obrigado